

Identificación de Sistemas No Lineales

Juan Carlos Gómez
Identificación de Sistemas
Departamento de Electrónica, FCEIA
Universidad Nacional de Rosario

Contenido

1. Introducción
2. Modelos No Lineales
3. Algunas Técnicas de Identificación de Modelos Hammerstein-Wiener


Introducción

- La mayoría de los sistemas tienen un comportamiento no lineal, excepto en un determinado rango de operación donde pueden ser considerados lineales.
- Modelos Lineales aproximan al sistema no lineal alrededor de un punto de operación.
- La performance del modelo lineal (i.e., sus características predictivas) se ven deterioradas al variar el punto de operación del sistema no lineal.
- Para describir globalmente el comportamiento del sistema se debe recurrir a Modelos No Lineales.


- La gran variedad de modelos no lineales hace que no sea posible obtener métodos generales de identificación, sino sólo para determinadas clases de modelos no lineales.
- Muchos sistemas no lineales pueden ser representados por la interconexión de sistemas lineales estacionarios y no linealidades estáticas. Estos modelos se denominan **orientados a bloques (block-oriented nonlinear models)**. Las no linealidades estáticas aparecen por ejemplo debido a saturación de actuadores, sensores con características no lineales, etc.
- De entre los modelos orientados a bloques, los que han sido más estudiados son los **Modelos Hammerstein** y los **Modelos Wiener**.

Modelos No Lineales

- Modelos Hammerstein



- Modelo Wiener



- Modelo Hammerstein-Wiener



- Modelos orientados a bloques: Incluyen los anteriores más otras posibles conexiones (serie, paralelo y en retroalimentación) de bloques LTI y no linealidades estáticas.

- Modelo regresivo lineal, con regresor como función no lineal de los datos pasados

$$\hat{y}(t, \theta) = \theta_1 \varphi_1(u^t, y^{t-1}) + \theta_2 \varphi_2(u^t, y^{t-1}) + \dots + \theta_d \varphi_d(u^t, y^{t-1}) = \varphi^T(t) \theta$$

φ_i funciones no lineales arbitrarias de los datos pasados

Problema \rightarrow Cómo elegir las funciones φ_i

Posibles soluciones

- ♦ Expansión tipo **caja negra**. Por ejemplo:
 $\varphi_i(u^t, y^{t-1})$ polinomios en las entradas y salidas pasadas.
- ♦ Uso de leyes fundamentales (física, química, etc.) para detectar las no linealidades en el sistema.

- Modelos No Lineales en Espacio de Estados

$$\begin{aligned}x(t+1) &= f(t, x(t), u(t), \omega(t), \theta) \\ y(t) &= h(t, x(t), u(t), v(t), \theta)\end{aligned}$$

donde

$\omega(t), v(t)$ son perturbaciones (procesos aleatorios)

θ vector de parámetros (desconocido)

NB: El problema de hallar un predictor óptimo para este modelo no lineal estocástico es muy difícil (no existe solución finito dimensional).

- Modelos No Lineales Tipo Caja Negra

Predictores de la forma:

$$\hat{y}(t | \theta) = g(Z^{t-1}, \theta) \quad (1)$$

donde

Z^{t-1} : datos pasados

$Z^t = (y^t, u^t) = (y(1), u(1), \dots, y(t), u(t))$

Problema \longrightarrow Cómo elegir $g(\bullet, \bullet)$

Posibles Soluciones

- Uso de regresores

$$g(Z^{t-1}, \theta) = g(\varphi(t), \theta)$$

con

$$\varphi(t) = \varphi(Z^{t-1}) \quad \text{vector de regresión}$$

- Un modelo más general sería permitiendo que el regresor dependa del parámetro

$$\varphi(t, \theta) = \varphi(Z^{t-1}, \theta)$$

- Con este enfoque, el problema de elegir $g(z^{t-1}, \theta)$ en (1) se descompone en dos problemas:
 1. Cómo elegir el vector de regresión $\varphi(t)$ como función de los datos pasados.
 2. Cómo elegir la función no lineal $g(\varphi, \theta)$.

- **Ejemplos de regresores**
 Por analogía con los modelos lineales se pueden obtener modelos NARX, NARMAX, NOE, NFIR.
 Los más comunes son modelos NARX y NFIR, en los cuales el regresor depende sólo de valores medidos (no estimados).

- **Ejemplos de funciones $g(\varphi, \theta)$**
 Típicamente se utiliza **expansión en funciones base**

$$g(\varphi, \theta) = \sum_{k=1}^n \alpha_k g_k(\varphi) \quad (2)$$

$\theta = [\alpha_1 \quad \cdots \quad \alpha_n]^T$ vector de parámetros

$g_k(\bullet)$: funciones bases

Problema Clave \longrightarrow **Cómo elegir las funciones base**
Posibles Soluciones

- **Series de Volterra**

$$g_k(\varphi) = \varphi^k$$

donde $\varphi^k = \{\varphi_1^{k_1} \varphi_2^{k_2} \cdots \varphi_d^{k_d}\}$, con

$$k_1 + k_2 + \cdots k_d = k$$

▣ Enfoques más modernos

Tienen las siguientes características:

- Todas las g_k están formadas a partir de una **función base madre** $\kappa(x)$.
- Esta función $\kappa(x)$ es función de una variable escalar x .
- Típicamente las g_k son versiones escaladas (dilatadas) y trasladadas de $\kappa(x)$.

Por ejemplo para $d=1$, se tendría

$$g_k(\varphi) = g_k(\varphi, \beta_k, \gamma_k) = \kappa(\beta_k(\varphi - \gamma_k))$$

donde β_k son los parámetros de escalado, y γ_k son los parámetros de traslación.

Ejemplos de 'funciones base madre'

➤ Serie de Fourier (caso escalar)

$$\kappa(x) = \cos(x)$$

➤ Funciones seccionalmente constantes

$$\kappa(x) = \begin{cases} 1 & \text{si } 0 \leq x \leq 1 \\ 0 & \text{cic} \end{cases}$$

con $\gamma_k = k\Delta$, $\beta_k = 1/\Delta$, y $\alpha_k = f(k\Delta)$. Esto da una aproximación seccionalmente constante de cualquier función en un intervalo Δ .

▣ Clasificación de Funciones Base

- **Bases Locales:** las variaciones significativas de la función se dan en un entorno.
- **Bases Globales:** tienen una variación significativa en todo el eje real.

□ Funciones Base Multivariables

➤ Producto Tensorial

$$g_k(\varphi) = g_k(\varphi, \beta_k, \gamma_k) = \prod_{j=1}^d \kappa(\beta_k^j (\varphi_j - \gamma_k^j))$$

➤ Construcción radial

Las funciones dependen sólo de la distancia de φ a un dado punto central (centro).

$$g_k(\varphi) = g_k(\varphi, \beta_k, \gamma_k) = \kappa(\|\varphi - \gamma_k\|_{\beta_k})$$

donde $\|\bullet\|_{\beta_k}$ denota una dada norma en el espacio de los regresores φ .
Típicamente

$$\|\varphi\|_{\beta_k}^2 = \varphi^T \beta_k \varphi$$

donde β_k es una matriz de escalado definida positiva.

➤ Construcción ridge

Las funciones dependen sólo de la distancia de φ a un dado hiperplano

$$g_k(\varphi) = g_k(\varphi, \beta_k, \gamma_k) = \kappa(\beta_k^T \varphi + \gamma_k) \quad , \quad \varphi \in \mathbb{R}^d$$

La función es constante para todos los φ que pertenecen al hiperplano

$$\{\varphi \in \mathbb{R}^d : \beta_k^T \varphi = \text{const}\}$$

▣ Calidad de la aproximación

El modelo usando expansión en funciones base resulta

$$g(\varphi, \theta) = \sum_{k=1}^n \alpha_k \kappa(\beta_k (\varphi - \gamma_k))$$

- ◆ Surge el interrogante de cuán bien esta expansión puede representar a cualquier posible sistema real ' $g_0(\varphi)$ '.

La respuesta es que (excepto para polinomios) cualquier función madre $\kappa(x)$ permite aproximar cualquier *razonable* $g_0(\varphi)$ arbitrariamente bien para un n suficientemente grande.


- ◆ Otro interrogante que surge es la *eficiencia* de la expansión, es decir cuán grande debe ser n para lograr un determinado grado de aproximación.

No hay una respuesta **general** para esto.

Identificación de Modelos Hammerstein

• Modelos Hammerstein

- ▣ Método no iterativo (Bai, 1998)



$$\begin{aligned} y_k &= \frac{B(q^{-1})}{A(q^{-1})} \sum_{i=1}^r c_i g_i(u_k) + v_k \\ &= \frac{B(q^{-1})}{A(q^{-1})} N(u_k) + v_k \end{aligned} \quad (1)$$

donde y_k , u_k y v_k son la salida, entrada y perturbación en el instante k , respectivamente, $g_i(\bullet)$ son funciones no lineales usadas para describir la no linealidad estática $N(\bullet)$, y

$$\begin{aligned} A(q^{-1}) &= 1 + a_1 q^{-1} + \dots + a_n q^{-n} \\ B(q^{-1}) &= b_1 q^{-1} + \dots + b_m q^{-m} \end{aligned} ,$$

con q^{-1} denotando el operador desplazamiento directo.

Se asume que los órdenes n, m, s , y las funciones no lineales $g_i(\bullet)$, son conocidas, y que el **objetivo** es estimar los parámetros de la parte lineal: $(a_1 \dots a_n b_1 \dots b_m)$, y de la parte no lineal: $(c_1 \dots c_r)$, a partir de datos de entrada-salida.

Una elección típica de las funciones $g_i(\bullet)$ es $g_i(u_k) = u_k^{i_k}$, en cuyo caso, la parte no lineal queda representada por una expansión polinomial.

La ecuación (1) puede escribirse

$$y_k = -\sum_{j=1}^n a_j y_{k-j} + \sum_{i=1}^r \sum_{j=1}^m b_j c_i u_k^{i_{k-j}} + v_k \quad (2)$$

Definiendo los vectores

$$\begin{aligned} \theta &= (a_1, \dots, a_n, b_1 c_1, \dots, b_m c_1, \dots, b_1 c_r, \dots, b_m c_r)^T \\ \phi_k &= (-y_{k-1}, \dots, -y_{k-n}, u_{k-1}, \dots, u_{k-m}, \\ &\quad u_{k-1}^2, \dots, u_{k-m}^2, \dots, \\ &\quad u_{k-1}^r, \dots, u_{k-m}^r)^T \end{aligned}$$

la ecuación (2) puede escribirse

$$y_k = \phi_k^T \theta + v_k \quad (3)$$

Finalmente, considerando el conjunto de N datos $\{y_k, u_k\}_{k=1}^N$, la ecuación (3) puede escribirse

$$Y_N = \Phi_N^T \theta + V_N \quad (4)$$

donde

$$\begin{aligned} Y_N &= (y_1, \dots, y_N)^T, \quad V_N = (v_1, \dots, v_N)^T, \\ \Phi_N &= (\phi_1, \dots, \phi_N) \end{aligned}$$

Luego, la estima de mínimos cuadrados $\hat{\theta}$, del vector de parámetros θ viene dada por

$$\hat{\theta} = (\Phi_N \Phi_N^T)^{-1} \Phi_N Y_N, \quad (5)$$

siempre que la inversa exista. Definiendo ahora los vectores

$$a = (a_1, \dots, a_n)^T, b = (b_1, \dots, b_m)^T, c = (c_1, \dots, c_r)^T$$

y la matriz

$$\Theta_{bc} = \begin{pmatrix} b_1 c_1 & b_1 c_2 & \cdots & b_1 c_r \\ b_2 c_1 & b_2 c_2 & \cdots & b_2 c_r \\ \vdots & \vdots & \ddots & \vdots \\ b_m c_1 & b_m c_2 & \cdots & b_m c_r \end{pmatrix} = bc^T,$$

el vector de parámetros θ puede escribirse

$$\theta = (a^T, \text{vec}(\Theta_{bc})^T)^T,$$

donde $\text{vec}(\Theta_{bc})$ es el vector columna obtenido apilando las columns de Θ_{bc} . Estimaciones de los vectores a y $\text{vec}(\Theta_{bc})$ pueden entonces obtenerse de la estima $\hat{\theta}$ en (5). Denotemos \hat{a} y $\hat{\text{vec}}(\Theta_{bc})$ a esas estimaciones.

El problema es como computar estimaciones de los vectores b y c , a partir de $\hat{\text{vec}}(\Theta_{bc})$.

Es claro que las más cercanas, en el sentido de la norma-2, estimaciones \hat{b} y \hat{c} , son tales que minimizan la norma

$$\left\| \text{vec}(\hat{b}\hat{c}^T) - \hat{\text{vec}}(\Theta_{bc}) \right\|_2^2 = \left\| \hat{b}\hat{c}^T - \hat{\Theta}_{bc} \right\|_F^2,$$

es decir

$$(\hat{b}, \hat{c}) = \underset{b, c}{\text{argmin}} \left\| \hat{\Theta}_{bc} - bc^T \right\|_F^2,$$

donde $\|\bullet\|_F$ es la norma de Frobenius.

La solución de este problema de minimización viene dada por la descomposición SVD de la matriz $\hat{\Theta}_{bc}$. El resultado está resumido en el siguiente Lema (Bai, 1998).

Sea $\hat{\Theta}_{bc} \in \Re^{m \times r}$ una matriz no nula, y sea $\hat{\Theta}_{bc} = USV^T$ su descomposición SVD, donde U y V son matrices ortogonales cuyas columnas son los vectores singulares izquierdos y derechos respectivamente,

$$U = (\mu_1, \mu_2, \dots, \mu_m), V = (v_1, v_2, \dots, v_r),$$

y donde S es una matriz diagonal con los valores singulares $(\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,r)} \geq 0)$ en la diagonal. Entonces

$$\min_{b,c} \|\hat{\Theta}_{bc} - bc^T\|_F^2 = \sum_{i=1}^{\min(m,r)} \sigma_i^2,$$

$$(\mu_1, \sigma_1 v_1) = \operatorname{argmin}_{b,c} \|\hat{\Theta}_{bc} - bc^T\|_F^2.$$

Prueba: Ver (Bai, 1998). ■

El **algoritmo** de identificación no lineal puede resumirse:

Paso 1. Computar la estima de mínimos cuadrados $\hat{\theta}$ en (5). Una estima \hat{a} del vector de parametros a viene dada por las primeras n componentes de $\hat{\theta}$, y una estima $\hat{\Theta}_{bc}$ de la matriz Θ_{bc} puede construirse a partir de las últimas $m \times r$ componentes de $\hat{\theta}$.

Paso 2. Computar la SVD de $\hat{\Theta}_{bc}$ como en el Lema, de donde estimas de los parametros b y c pueden calcularse como

$$\hat{b} = \mu_1,$$

y

$$\hat{c} = \sigma_1 v_1,$$

respectivamente.